

Trabalho de PAA

Taynara Dutra, Tiago Funk e Rafael Tenfen

Problema do Auditório

- Dada uma lista de tarefas a serem executadas com um horário de início e um horário de término, determinar qual a quantidade máxima de atividades que podem ser executadas
- Um auditório só pode ser utilizado para um evento por vez. Em um dia com muitos eventos, deseja-se determinar qual é o maior número de eventos que podem ser realizados no auditório, e quais são eles (OBS: pode haver mais de uma solução).
- Imagine o seguinte quadro de reservas

Evento	1	2	3	4	5	6	7	8	9	10	11
Início	3	8	5	1	6	12	0	8	5	2	3
Término	5	11	7	4	10	14	6	12	9	13	8


- Para encontrar o tamanho de um subconjunto sem sobreposição máximo, poderíamos utilizar:

Solução gulosa

- Ordenamos os eventos pelo horário de término (em ordem crescente) e sempre que possível pegamos o evento com menor horário de término.

Conjunto de atividades

i	1	2	3	4	5	6	7	8	9	10	11
$s[i]$	1	3	0	5	3	5	6	8	8	2	12
$f[i]$	4	5	6	7	8	9	10	11	12	13	14



Uma subcoleção disjunta máxima: $\{a_1, a_4, a_8, a_{11}\}$

Relatório de execução e análise de gráficos

- Foram realizadas execuções com vetores de tamanho 270000, 810000, 2430000, 7290000, 21870000 e 65610000. Sendo estes valores limitados pela capacidade e quantidade de hardware disponível.

Hardware Utilizado

- 32 GB de memória RAM
- Processador de ryzen 9 5900X, de 12 núcleos e 24 threads

Execuções

- Para cada tamanho de vetor descrito anteriormente foram realizados 30 testes, com o intuito de obter maior garantia da confiabilidade dos dados.
- Os dados obtidos nas execuções foram agrupados e realizado a média dos valores, conforme dispostos abaixo.

```
(data.agg = aggregate(TIME ~ SIZE, data = data.csv, FUN = mean))
```

```
##      SIZE      TIME
## 1  270000 0.03055393
## 2  810000 0.09204820
## 3 2430000 0.29007650
```

```
## 4 7290000 0.90334187
## 5 21870000 2.93992123
## 6 65610000 9.52904380
```

Verificando o nível de confiança dos dados obteve-se o seguinte:

- Para testar se os dados gerados são confiáveis, foi utilizado o shapiro test, uma breve explicação foi retirada da documentação:

Shapiro-Wilks Normality Test

- The Shapiro-Wilks test for normality is one of three general normality tests designed to detect all departures from normality. It is comparable in power to the other two tests.
- The test rejects the hypothesis of normality when the p-value is less than or equal to 0.05. Failing the normality test allows you to state with 95% confidence the data does not fit the normal distribution. Passing the normality test only allows you to state no significant departure from normality was found.
- The Shapiro-Wilks test is not as affected by ties as the Anderson-Darling test, but is still affected. The Skewness-Kurtosis All test is not affected by ties and thus the default test.

```
(data.agg.shapiro = shapiro.test(data.csv$TIME))
```

```
##
## Shapiro-Wilk normality test
##
## data: data.csv$TIME
## W = 0.65056, p-value < 2.2e-16
```


```
percentageConfiance = (1 - data.agg.shapiro$p.value) * 100
```

- O teste apresenta um p-value próximo de: 0 o que torna válido um nível de confiança de aproximadamente até: 100 %

Análise dos gráficos

- Os gráficos foram gerados utilizando-se de duas ferramentas, no R Studio e no Excel.
- A imagem abaixo apresenta o gráfico plotado na ferramenta R Studio com a relação do tempo de execução versus tamanho do vetor.


```
plot(data.agg$SIZE, data.agg$TIME, type = "b", col="GREEN", xlab="Tamanho do Vetor", ylab="Tempo de Exe
```



Demais gráfico dos tempos obtidos


- Bloxplot

```
boxplot(data.csv$TIME, horizontal = T)
```



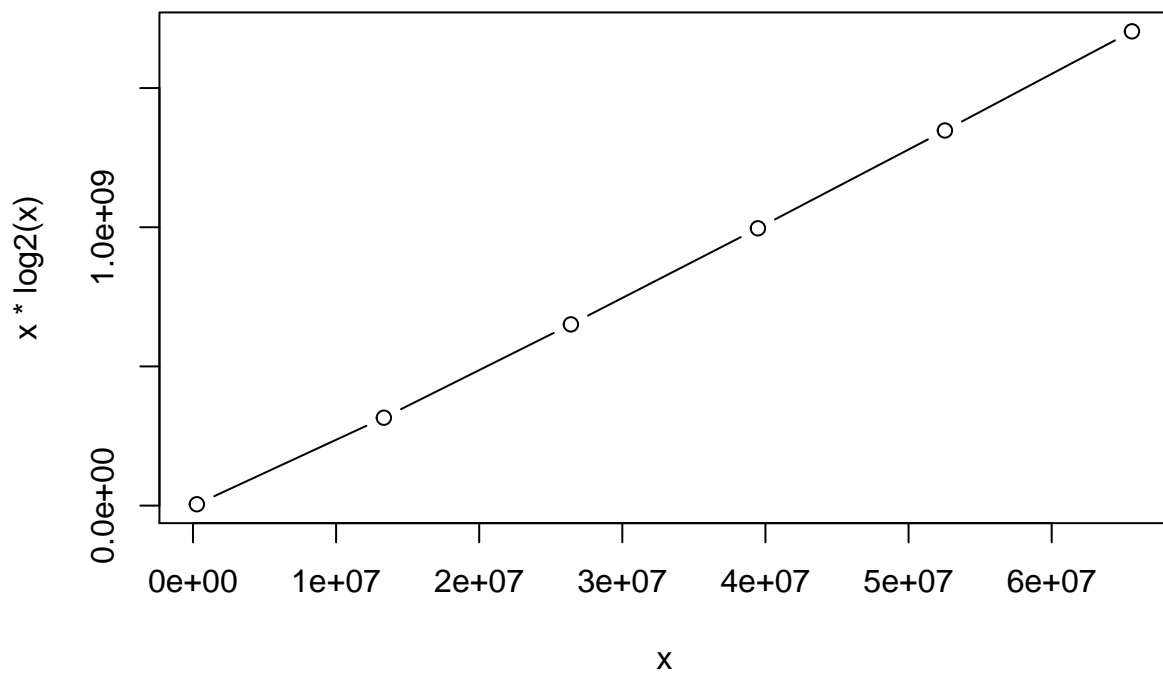
```
#plot(ecdf(data.csv$TIME))
#hist(data.csv$SIZE / data.csv$TIME, col = "GREEN", breaks=100)
```

- Dessa forma, constata-se que a linha traçada segue a curvatura esperada para uma função de $n \log n$. Conforme mostrado pela figura abaixo.

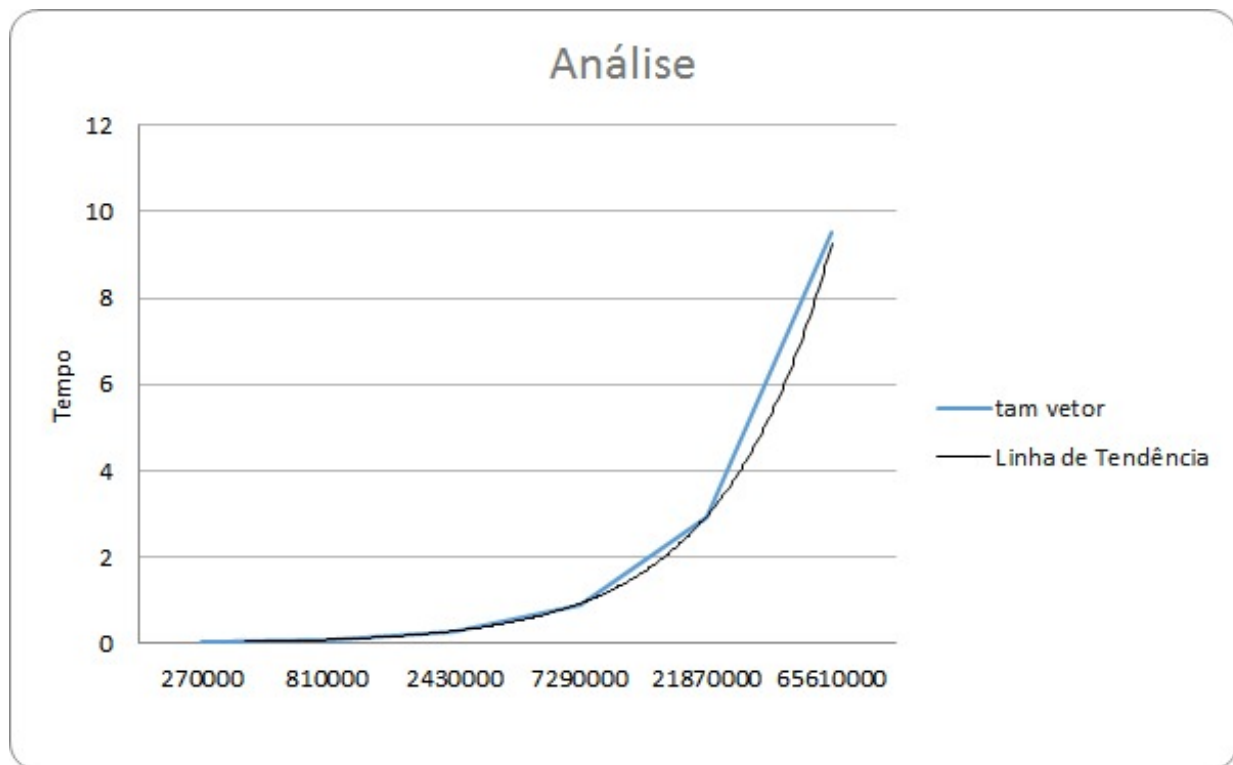


- A linha de tendência foi plotada em outro gráfico, devido as escalas não condizerem com a realidade. Não sendo possível unir os dados para que estes fossem gerados no mesmo gráfico. Já que as escalas da função $n \log n$, com base nos tamanhos dos vetores gerados serem grandes e a execução do programa se realizar de maneira muito rápida, as duas escalas não são compatíveis e não estão no mesmo intervalo. Assim, a linha de tendência para a função $n \log n$ gerada no R studio é apresentado a seguir.

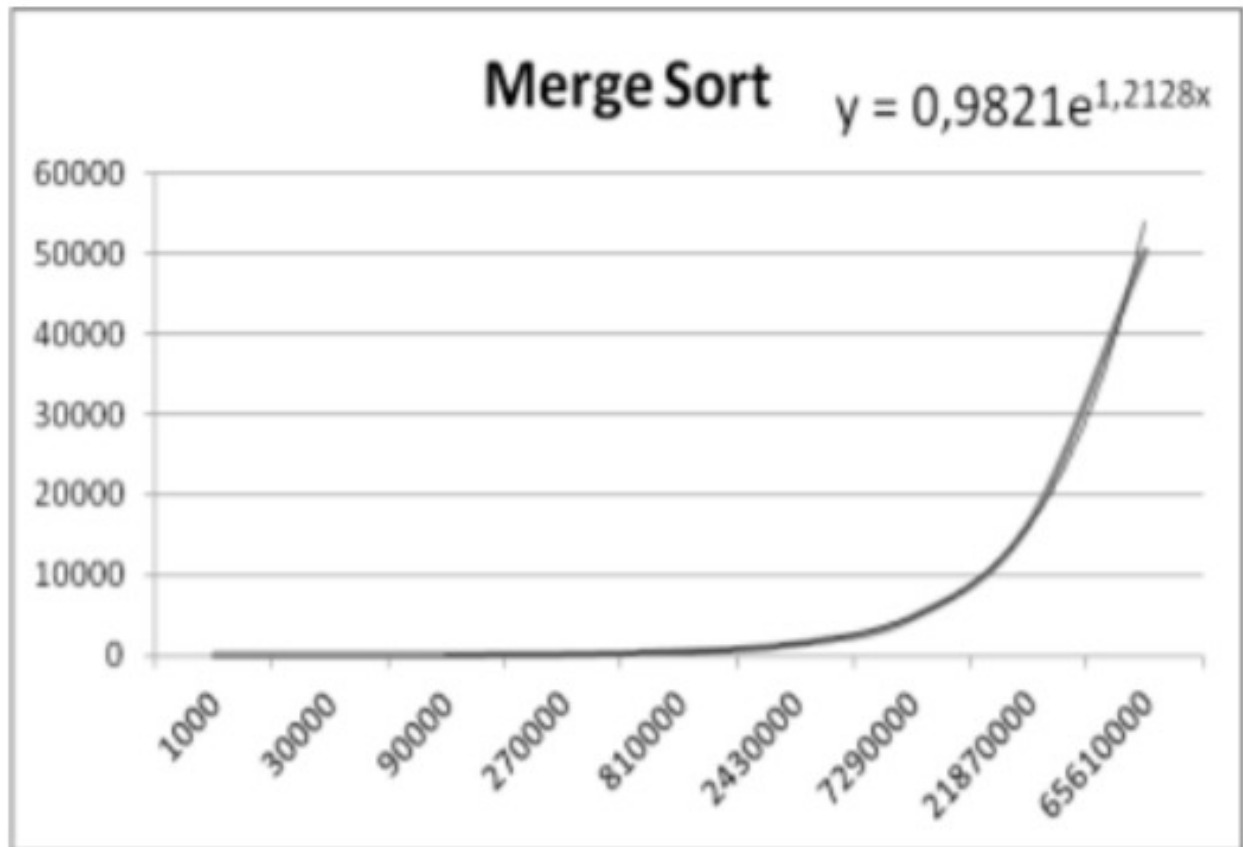
```
curve(x * log2(x), from=min(data.agg$SIZE), to=max(data.agg$SIZE), n = length(data.agg$SIZE), type = "b")
```



- De maneira, a complementar o entendimento a respeito dos dados obtidos, um novo gráfico foi gerado na ferramenta Excel e está adicionado abaixo.



- Por este é possível constatar que ele segue a curvatura de uma função de merge, conforme o gráfico posterior a ele, que utilizamos como referência.



- Segundo o autor Matusso Jr. (2013) deste exemplo acima, a linha de tendência utilizada para analisar este tipo de gráfico é do tipo “exponencial”, a qual sugere o comportamento $O(n \log n)$. Assim, a linha de tendência e a linha dos dados podem ser visualizados no mesmo gráfico.

Referências

- Matusso Jr, Mario E. 2013. Análise empírica de algoritmos de ordenação. Disponível em: <http://matusso.dx.am/Arquivos/ArtigoAED.pdf> Acesso em: 23/06/2021.